

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

Inteligência Artificial e Ilusão de Inteligência

Semana 14 — Fundamentos de Aprendizagem por Reforço

Módulo 6: Como um agente aprende?

Apostila: Parte VI, Cap. 12 (12.1 a 12.5, e 12.9 como contextualização)

Micro Game: Adaptive AI — Coletor de Recompensas (início — planejamento e setup)

IFMS • Semana 14

Objetivos da aula

Ao final de hoje você será capaz de:

- distinguir programação explícita de aprendizado pela interação;
- definir o vocabulário fundamental do RL: agente, ambiente, estado, ação, recompensa, episódio, política;
- explicar o ciclo de aprendizagem e o retorno com desconto (γ);
- relacionar o MDP e a propriedade de Markov a um bom estado;
- diferenciar valor de estado $V(s)$ e valor de ação $Q(s, a)$.

Retomada da Semana 13

Semana 13: encerramento do Módulo 5 — Algoritmos Genéticos, convergência, aplicações e ferramentas (GeneticSharp, NEAT).



Hoje abrimos o Módulo 6 e a Unidade VI: uma nova família de problemas — agentes que aprendem pela interação.

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência



Como um agente aprende?

Parte 1 — vocabulário, ciclo de aprendizagem e fundamentos matemáticos.

IFMS • Semana 14

O problema

Alguns comportamentos são difíceis de programar à mão — equilibrar-se, perseguir um alvo em terreno irregular, adaptar-se a um oponente imprevisível.



RL propõe outro caminho: em vez de codificar a regra, o agente **aprende** a política pela interação com o ambiente.

RL não é aprendizado supervisionado

Aprendizado Supervisionado	Aprendizagem por Reforço
Exemplos rotulados (entrada → saída correta)	Nenhum "gabarito" de ações
Erro medido diretamente	Apenas um sinal de recompensa, esparsos e atrasados
Aprende a imitar	Aprende a agir por tentativa e erro

O laço agente-ambiente



O agente observa o estado, escolhe uma ação, recebe uma recompensa e um novo estado — o ciclo se repete a cada passo.

Vocabulário fundamental

- **Agente:** quem decide e age;
- **Ambiente:** tudo com que o agente interage;
- **Estado:** a representação da situação atual;
- **Ação:** o que o agente pode fazer;
- **Recompensa:** sinal numérico de retorno imediato;
- **Episódio:** uma sequência completa até um estado terminal;
- **Política:** a regra que mapeia estado → ação.

⊘ **ERRO COMUM**

Erro comum: projetar a recompensa para o meio (a ação desejada) em vez do fim (o resultado desejado) — risco de *reward hacking*, como no caso documentado do jogo *CoastRunners*.

Exploração *versus* exploitation

Um agente que só explora nunca converge; um agente que só faz *exploitation* pode travar em um ótimo local.



Estratégia comum: **ϵ -greedy** — na maior parte do tempo escolhe a melhor ação conhecida, mas ocasionalmente explora ao acaso.

O ciclo de aprendizagem em cinco etapas

1. **Observar** o estado atual;
2. **Decidir** uma ação (política atual);
3. **Agir** no ambiente;
4. **Receber** a recompensa e o novo estado;
5. **Atualizar** a política com base no resultado.

Retorno acumulado e desconto (γ)

O agente não maximiza apenas a recompensa imediata, mas o **retorno** — a soma das recompensas futuras, ponderada por um fator de desconto γ ($0 \leq \gamma \leq 1$).



γ próximo de 1: o agente valoriza recompensas distantes. γ próximo de 0: o agente é "imediatista".

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência



Processo de Decisão de Markov (MDP)

Formalizando o cenário de decisão.

IFMS • Semana 14

Estados, ações, transições, recompensas

Um MDP formaliza o problema como: **estados**, **ações** disponíveis, **transições** entre estados e **recompensas** associadas.

⚠️ ATENÇÃO

Propriedade de Markov: o estado deve conter tudo o que é relevante para decidir — o futuro não pode depender do histórico, só do estado atual. É uma hipótese de projeto, não uma garantia automática.

Um bom estado é uma escolha de projeto

Omitir velocidade ou direção quando são relevantes pode violar a propriedade de Markov — o agente perde informação necessária para decidir bem.



Pergunta de verificação: para cada observação omitida, ela poderia ser necessária para a decisão?

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência



Função valor: $V(s)$ e $Q(s, a)$

Diferenciando recompensa de valor.

IFMS • Semana 14

Recompensa imediata × valor de longo prazo

- **Recompensa:** o sinal recebido em um único passo;
- **Valor de estado $V(s)$:** o retorno esperado a partir de um estado;
- **Valor de ação $Q(s, a)$:** o retorno esperado ao tomar a ação a no estado s .

DICA

Paralelo já conhecido: $Q(s, a)$ cumpre papel semelhante ao da função de avaliação do Minimax (Módulo 4) e do mapa de influência (Módulo 3) — reduz a decisão a "escolher o maior valor".

⊘ **ERRO COMUM**

Erro comum: confundir valor com recompensa, avaliando decisões apenas pelo ganho imediato — uma ação pode ter recompensa baixa e valor alto (ou o inverso).

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

ML-Agents — contextualização de ferramenta

Sem configuração de treinamento nesta semana.

IFMS • Semana 14

O que o ML-Agents faz

O ML-Agents é a ferramenta oficial da Unity que materializa o vocabulário do RL na engine:

- observações, ações e recompensa são definidas em C#;
- o treinamento roda em Python;
- a política treinada é executada na Unity via **Sentis**.

⚠ ATENÇÃO

Nesta semana: apenas contextualização. Nenhum componente de ML-Agents será configurado.

NA INDÚSTRIA

Exemplos oficiais do ML-Agents (Walker, Crawler) mostram criaturas aprendendo a caminhar pela interação — sem nenhuma regra de locomoção programada à mão.

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

Micro Game Adaptive AI — planejamento

Antes de treinar, é preciso planejar.

IFMS • Semana 14

O que planejar hoje

Sem configurar ML-Agents ainda, cada grupo define, por escrito:

- o **estado** (quais observações o agente terá);
- o **espaço de ações** disponível (discretas ou contínuas);
- a **função de recompensa** planejada.

DICA

Verificar: o estado escolhido respeita a propriedade de Markov? A recompensa premia o resultado desejado, e não apenas a ação?

Cenário mínimo na Unity

Tema fixo do Micro Game: **Coletor de Recompensas** — um agente que aprende a coletar itens positivos e evitar itens negativos.

Montar o cenário com elementos primitivos simples (cubos, esferas, planos): agente, ambiente, itens positivos e negativos.

⚠️ ATENÇÃO

Nenhum componente de ML-Agents é configurado nesta semana — o cenário fica pronto para receber o treinamento na Semana 15.

Esqueleto do script **Agent** em C#

Antes da Semana 15, cada grupo traduz o planejamento em código — sem configurar ML-Agents nem treinar:

- método de **coleta de observações** (o estado definido);
- método de **execução de ações** (o espaço de ações definido);
- método de **atribuição de recompensa** (a função de recompensa definida).

DICA

Objetivo conceitual: tornar visível que estado, ação e recompensa viram três métodos. A Semana 15 começa direto na configuração e no treinamento.



Erro comum

Tentar, por entusiasmo, configurar ou treinar o ML-Agents nesta semana, antecipando a Semana 15.

OBJETIVOS

Esta semana é de planejamento conceitual — a configuração técnica será conduzida com cuidado na próxima aula.

Resumo da semana

- RL: aprender pela interação, não por exemplos rotulados
- Vocabulário: agente, ambiente, estado, ação, recompensa, episódio, política
- Ciclo de cinco etapas e retorno acumulado com desconto γ
- MDP e propriedade de Markov: um bom estado é uma escolha de projeto
- $V(s)$ e $Q(s, a)$: valor $\neq$ recompensa imediata
- ML-Agents apresentado como ferramenta — sem treinamento ainda
- Micro Game Adaptive AI (Coletor de Recompensas): planejamento de estado, ações e recompensa, e esqueleto do script `Agent` em C#

Preparação para a Semana 15

Tema: Treinamento com ML-Agents

- Leitura prévia da seção 12.6 (Q-Learning) e, se possível, 12.9 completa
- Antecipar a instalação do ambiente ML-Agents (Python e pacotes)



Trazer o planejamento validado de estado, ações e recompensa — ele será operacionalizado na Semana 15.