

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

Inteligência Artificial e Ilusão de Inteligência

Semana 15 — Treinamento com ML-Agents

Módulo 6: Como um agente aprende?

Apostila: Parte VI, Cap. 12, seção 12.6 (Q-Learning) e seção 12.9 (ML-Agents)

Micro Game: Adaptive AI — Coletor de Recompensas (treinamento efetivo)

IFMS • Semana 15

Objetivos da aula

Ao final de hoje você será capaz de:

- calcular a atualização de uma célula $Q(s, a)$ com a equação de Bellman;
- explicar por que uma rede neural substitui a tabela Q em espaços grandes;
- configurar os componentes básicos de um agente treinável no ML-Agents;
- interpretar a curva de recompensa de um treinamento em andamento.

Retomada da Semana 14

Semana 14: vocabulário do RL (agente, ambiente, estado, ação, recompensa), MDP, propriedade de Markov, $V(s)$ e $Q(s, a)$. Planejamento do Adaptive AI, sem configurar ferramentas.



Hoje o planejamento vira código: o agente será treinado de verdade.

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência



Como um agente aprende?

Parte 2 — Q-Learning, treinamento e leitura da curva de recompensa.

IFMS • Semana 15

A tabela Q

Uma forma concreta de guardar $Q(s, a)$: uma tabela com um estado por linha e uma ação por coluna.



Decidir vira simples: em cada estado, escolher a ação da coluna com maior valor.

O limite da tabela

A tabela Q exige uma linha para **cada** estado possível.

⚠️ ATENÇÃO

Em espaços de estado grandes ou contínuos (posição, velocidade, ângulo), o número de linhas explode — a tabela deixa de ser viável.

A equação de Bellman

$$Q(s,a) \leftarrow Q(s,a) + \alpha \cdot [r + \gamma \cdot \max_{a'} Q(s',a') - Q(s,a)]$$

- **r**: recompensa imediata
- **$\gamma \cdot \max_{a'} Q(s',a')$** : melhor valor futuro estimado
- **α** : taxa de aprendizagem — quanto o novo valor pesa sobre o antigo

Exemplo — trilha S1 a S5

Uma trilha linear de cinco estados; recompensa só ao alcançar S5.

DICA

A cada atualização, parte do valor da recompensa terminal "escorre" para trás, de $Q(S4, \rightarrow)$ até $Q(S1, \rightarrow)$ — é assim que o agente aprende a valorizar estados distantes do objetivo.

⊘ **ERRO COMUM**

Erro comum: tratar cada atualização de $Q(s, a)$ como definitiva. Na prática, o valor se ajusta aos poucos, por muitas repetições da mesma transição.

Da tabela à rede neural

Se a tabela não cabe, algo precisa **aproximar** a função Q — esse algo é uma rede neural.



DICA

O PPO, algoritmo do ML-Agents, resolve o mesmo problema do Q-Learning (estimar valor/política) por um caminho diferente: aproximação em vez de tabela.

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

ML-Agents — da teoria ao componente

Configurando o agente do Adaptive AI.

IFMS • Semana 15

Três componentes na cena

- **Agent (C#):** implementa observações, ações e recompensa;
- **Behavior Parameters:** define o formato de entrada/saída da política;
- **Decision Requester:** solicita decisões em intervalos regulares.

Do vocabulário ao código



Estado → ação → recompensa, o mesmo ciclo da Semana 14, agora em métodos C#.

IFMS • Semana 15

Hiperparâmetros básicos

Hiperparâmetro	Efeito qualitativo
Taxa de aprendizagem	Passos maiores ou menores na atualização da política
Tamanho de lote	Estabilidade da estimativa a cada atualização
Unidades ocultas	Capacidade da rede para representar a política
Passos máximos	Duração total do treinamento

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

Laboratório — treinamento efetivo

Da configuração à curva de recompensa.

IFMS • Semana 15

O que fazer hoje

Treinar o agente do Coletor de Recompensas (coletar itens positivos, evitar itens negativos):

1. Configurar o YAML com os hiperparâmetros básicos;
2. iniciar o treinamento via linha de comando;
3. acompanhar a curva de recompensa no TensorBoard;
4. registrar o modelo `.onnx` gerado ao final.

Lendo a curva de recompensa

⚠️ ATENÇÃO

Curva subindo de forma gradual: aprendizado em progresso. Curva estagnada ou instável: sinal de problema a diagnosticar.

Três suspeitos mais prováveis: recompensa mal especificada, estado insuficiente, hiperparâmetros inadequados.

NA INDÚSTRIA

Nos exemplos oficiais do ML-Agents (Walker, Crawler), a curva de recompensa sobe de forma gradual ao longo de milhares de passos — não em minutos.



Erro comum

Esperar que o agente aprenda de forma visível em poucos minutos, ou confundir treinar (ML-Agents) com executar (Sentis, Semana 16).

OBJETIVOS

Treinamento é um processo gradual e monitorado — não um resultado instantâneo.

Resumo da semana

- Tabela Q: estrutura, decisão e limite de escala
- Equação de Bellman e exemplo da trilha S1–S5
- Rede neural como substituta da tabela em espaços grandes
- Componentes do ML-Agents: Agent, Behavior Parameters, Decision Requester
- Hiperparâmetros básicos de treinamento
- Treinamento efetivo do Adaptive AI e leitura da curva de recompensa

Preparação para a Semana 16

Tema: Inferência com Sentis e consolidação

- Preservar o modelo `.onnx` e a curva de recompensa registrada
- Leitura prévia da seção 12.9 (parte de inferência)



DICA

Semana 16 encerra o Módulo 6 com quatro entregas: Adaptive AI consolidado (50%), AI Design Log (25%), Desafio de Escolha Tecnológica (15%) e Engenharia Reversa (10%).