

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

Inteligência Artificial e Ilusão de Inteligência

Semana 15 — Treinamento com ML-Agents

Módulo 6: Como um agente aprende?

Apostila: Parte VI, Cap. 12, seção 12.6 (Q-Learning) e seção 12.9 (ML-Agents)

Micro Game: Adaptive AI (treinamento efetivo)

IFMS • Semana 15

Objetivos da aula

Ao final de hoje você será capaz de:

- calcular a atualização de uma célula $Q(s, a)$ com a equação de Bellman;
- explicar por que uma rede neural substitui a tabela Q em espaços grandes;
- configurar os componentes básicos de um agente treinável no ML-Agents;
- interpretar a curva de recompensa de um treinamento em andamento.

Retomada da Semana 14

Semana 14: vocabulário do RL (agente, ambiente, estado, ação, recompensa), MDP, propriedade de Markov, $V(s)$ e $Q(s, a)$. Planejamento do Adaptive AI, sem configurar ferramentas.



Hoje o planejamento vira código: o agente será treinado de verdade.

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência



Como um agente aprende?

Parte 2 — Q-Learning, treinamento e leitura da curva de recompensa.

IFMS • Semana 15

A tabela Q

Uma forma concreta de guardar $Q(s, a)$: uma tabela com um estado por linha e uma ação por coluna.



Decidir vira simples: em cada estado, escolher a ação da coluna com maior valor.

O limite da tabela

A tabela Q exige uma linha para **cada** estado possível.

⚠ ATENÇÃO

Em espaços de estado grandes ou contínuos (posição, velocidade, ângulo), o número de linhas explode — a tabela deixa de ser viável.

A equação de Bellman

$$Q(s,a) \leftarrow Q(s,a) + \alpha \cdot [r + \gamma \cdot \max_{a'} Q(s',a') - Q(s,a)]$$

- **r**: recompensa imediata
- **$\gamma \cdot \max_{a'} Q(s',a')$** : melhor valor futuro estimado
- **α** : taxa de aprendizagem — quanto o novo valor pesa sobre o antigo

Exemplo — trilha S1 a S5

Uma trilha linear de cinco estados; recompensa só ao alcançar S5.



DICA

A cada atualização, parte do valor da recompensa terminal "escorre" para trás, de $Q(S4, \rightarrow)$ até $Q(S1, \rightarrow)$ — é assim que o agente aprende a valorizar estados distantes do objetivo.

⊘ **ERRO COMUM**

Erro comum: tratar cada atualização de $Q(s, a)$ como definitiva. Na prática, o valor se ajusta aos poucos, por muitas repetições da mesma transição.

Da tabela à rede neural

Se a tabela não cabe, algo precisa **aproximar** a função Q — esse algo é uma rede neural.



DICA

O PPO, algoritmo do ML-Agents, resolve o mesmo problema do Q-Learning (estimar valor/política) por um caminho diferente: aproximação em vez de tabela.

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

ML-Agents — da teoria ao componente

Configurando o agente do Adaptive AI.

IFMS • Semana 15

Três componentes na cena

- **Agent (C#):** implementa observações, ações e recompensa;
- **Behavior Parameters:** define o formato de entrada/saída da política;
- **Decision Requester:** solicita decisões em intervalos regulares.

Do vocabulário ao código



Estado → ação → recompensa, o mesmo ciclo da Semana 14, agora em métodos C#.

IFMS • Semana 15

[!FIGURA]

Objetivo didático

Mostrar a correspondência entre o planejamento de estado/ação/recompensa da Semana 14 e os componentes reais do ML-Agents na cena do Adaptive AI.

Arquivo sugerido

`assets/componentes-mlagents-adaptive-ai.webp`

Descrição

Captura do Inspector da Unity mostrando um GameObject com os componentes Agent, Behavior Parameters e Decision Requester configurados, com anotações apontando para cada um.

Como produzir

Captura de tela direta da cena montada na Semana 14, com anotações adicionadas em Krita.

Hiperparâmetros básicos

Hiperparâmetro	Efeito qualitativo
Taxa de aprendizagem	Passos maiores ou menores na atualização da política
Tamanho de lote	Estabilidade da estimativa a cada atualização
Unidades ocultas	Capacidade da rede para representar a política
Passos máximos	Duração total do treinamento

Tecnologia em Jogos Digitais • Inteligência Artificial e Ilusão de Inteligência

Laboratório — treinamento efetivo

Da configuração à curva de recompensa.

IFMS • Semana 15

O que fazer hoje

1. Configurar o YAML com os hiperparâmetros básicos;
2. iniciar o treinamento via linha de comando;
3. acompanhar a curva de recompensa no TensorBoard;
4. registrar o modelo `.onnx` gerado ao final.

Lendo a curva de recompensa

⚠ ATENÇÃO

Curva subindo de forma gradual: aprendizado em progresso. Curva estagnada ou instável: sinal de problema a diagnosticar.

Três suspeitos mais prováveis: recompensa mal especificada, estado insuficiente, hiperparâmetros inadequados.

NA INDÚSTRIA

Nos exemplos oficiais do ML-Agents (Walker, Crawler), a curva de recompensa sobe de forma gradual ao longo de milhares de passos — não em minutos.



Erro comum

Esperar que o agente aprenda de forma visível em poucos minutos, ou confundir treinar (ML-Agents) com executar (Sentis, Semana 16).

OBJETIVOS

Treinamento é um processo gradual e monitorado — não um resultado instantâneo.

Resumo da semana

- Tabela Q: estrutura, decisão e limite de escala
- Equação de Bellman e exemplo da trilha S1–S5
- Rede neural como substituta da tabela em espaços grandes
- Componentes do ML-Agents: Agent, Behavior Parameters, Decision Requester
- Hiperparâmetros básicos de treinamento
- Treinamento efetivo do Adaptive AI e leitura da curva de recompensa

Preparação para a Semana 16

Tema: Inferência com Sentis e consolidação

- Preservar o modelo `.onnx` e a curva de recompensa registrada
- Leitura prévia da seção 12.9 (parte de inferência)



DICA

Semana 16 encerra o Módulo 6: Desafio de Escolha Tecnológica e Engenharia Reversa.